Dinâmicas de Veracidade na Era da Pós-Verdade: Dos Limites do Processamento de Linguagem Natural à Geometria da Disseminação por Redes Neurais de Grafos

A era contemporânea, frequentemente denominada como a "era da pós-verdade", representa uma mudança paradigmática na forma como a informação é consumida, processada e validada pela sociedade.[1] Este fenômeno é caracterizado por circunstâncias em que fatos objetivos possuem menos influência na formação da opinião pública do que apelos a emoções e crenças pessoais.[3] No epicentro desta crise epistemológica encontra-se a proliferação de notícias falsas, ou *fake news*, que são informações deliberadamente fabricadas para enganar leitores com o objetivo de obter ganhos políticos ou financeiros.[3] Embora a detecção automática dessas informações tenha avançado significativamente por meio do Processamento de Linguagem Natural (NLP), as abordagens centradas exclusivamente no conteúdo enfrentam barreiras críticas de escalabilidade linguística e adaptação contextual.[7] A transição de modelos treinados em inglês formal para contextos de redes sociais e múltiplas línguas revela uma perda acentuada de precisão, forçando a academia a buscar soluções que transcendam o texto.[5] Nesse cenário, a geometria da rede e os padrões de propagação surgem como assinaturas de veracidade mais robustas e independentes de idioma, permitindo que a detecção se baseie na forma como a notícia se dissemina e na estrutura das comunidades que a consomem.[11]

A Arquitetura da Pós-Verdade e o Desafio da Veracidade

O termo "pós-verdade" ganhou proeminência global em 2016, quando foi selecionado como a palavra do ano pelo Oxford Dictionaries, refletindo o clima político do referendo do Brexit e das eleições presidenciais nos Estados Unidos.[1] Conceitualmente, a pós-verdade não se refere apenas a mentiras, mas a um estado de "supremacia ideológica" onde os praticantes tentam compelir outros a acreditar em algo, independentemente de evidências.[4] Esta realidade é exacerbada pela erosão da confiança nas instituições tradicionais de conhecimento, como o jornalismo profissional e a ciência, que perdem seu papel de "árbitros do saber" para fluxos de informação horizontais e algoritmos de engajamento.[1]

A desinformação moderna não é um fenômeno isolado, mas um processo sociotécnico

complexo que envolve a criação intencional, a transmissão heteromórfica e a recepção controversa.[15] A facilidade de criação de contas automatizadas (bots) e o uso de ferramentas de Inteligência Artificial Generativa, como Grandes Modelos de Linguagem (LLMs), permitem que notícias falsas se tornem virais em segundos, atingindo milhões de usuários antes que qualquer processo de checagem manual possa intervir.[6]

Categoria	Descrição	Motivação Primária
Fake News	Notícias completamente fabricadas e verificavelmente falsas.[16]	Lucro financeiro ou influência política.[3]
Sátira	Conteúdo humorístico que mimetiza o formato de notícia.[9]	Entretenimento ou crítica social.
Propaganda	Informação partidária que mistura fatos reais para induzir conclusões falsas.[3]	Mobilização ideológica.
Clickbait	Manchetes sensacionalistas para atrair cliques para anúncios.[16]	Ganho financeiro.
Rumor	Informação sem verificação imediata que circula em redes sociais.[13]	Incerteza social ou curiosidade.

Historicamente, o uso de falsidades para manipulação política remonta a eventos como a rivalidade entre Otaviano e Marco Antônio, mas a escala atual é sem precedentes devido à hiperconectividade digital.[3] A transição da "Era da Informação" para a "Era da Pós-Verdade" é marcada por uma sobrecarga informativa onde a verdade se torna um evento processual em vez de uma propriedade estática.[4]

Detecção por Processamento de Linguagem Natural: O Estado da Arte

As primeiras tentativas de detecção automática de desinformação focaram nas propriedades intrínsecas do texto. A premissa fundamental é que a linguagem enganosa possui marcadores linguísticos, estilísticos e sintáticos distintos das notícias legítimas.[17]

Abordagens Baseadas em Atributos Linguísticos

Modelos clássicos utilizam aprendizado de máquina supervisionado para classificar notícias com base em vetores de características extraídos do conteúdo.[7] Entre as técnicas mais comuns estão o Bag of Words (BOW) e o TF-IDF (Term Frequency-Inverse Document Frequency), que analisam a frequência de termos para identificar padrões de uso de palavras associados à desinformação.[16] Estudos indicam que algoritmos como Support Vector Machines (SVM) e Random Forest alcançam precisão em torno de 80% a 83% em conjuntos de dados padronizados.[7]

Além da frequência de termos, a análise sintática profunda e a estilometria revelam que notícias falsas tendem a ter menor concentração de tópicos e maior incerteza temática do que notícias reais.[17] Outra característica marcante é o uso de linguagem intensa e apelos emocionais, frequentemente detectados por análise de sentimento, que servem como filtros complementares em sistemas de detecção multicamadas.[9]

O Impacto dos Modelos de Linguagem Pré-treinados

A introdução de modelos baseados na arquitetura Transformer, como o BERT (Bidirectional Encoder Representations from Transformers), revolucionou a detecção por NLP. Ao contrário de modelos sequenciais como as Redes de Memória de Longo Prazo (LSTM), o BERT captura o contexto bidirecional de cada palavra, permitindo uma compreensão profunda de ambiguidades e ironias.[5]

Modelo	Acurácia Relatada	Vantagens
Regressão Logística	~80%	Simplicidade e baixo custo computacional.[7]
Random Forest	~83%	Melhor manejo de dados não lineares.[7]
LSTM	~87%	Captura dependências sequenciais.[7]
BERT	~92%	Compreensão contextual bidirecional profunda.[5]
GPT-4 Omni	~98.6%	Desempenho superior em tarefas contextuais

		complexas.[20]

No entanto, a dependência exclusiva do conteúdo textual torna esses modelos vulneráveis. Propagadores de desinformação podem utilizar tecnologias de *deepfake* textual para mimetizar estilos de escrita de veículos jornalísticos confiáveis, evadindo detectores baseados apenas em estilo.[21]

Limitações de NLP: O Abismo Linguístico e Contextual

Apesar da alta eficácia em laboratório, a aplicação real de modelos de NLP enfrenta o que se pode chamar de "abismo de generalização". Este problema manifesta-se em três frentes principais: a mudança de idioma, a variação entre registros formais e informais, e a assimetria entre línguas de alta e baixa disponibilidade de recursos.[9]

O Problema da Tradução e a Assimetria de Treinamento

A detecção de notícias falsas é predominantemente centrada na língua inglesa. Quando esses modelos são transpostos para outros idiomas sem dados de treinamento nativos, a precisão cai drasticamente.[22] Uma descoberta crucial na área de detecção translinguística (CLFND) é a assimetria de desempenho baseada na "inclusividade" da língua de origem.[5]

Pesquisas comparando o chinês e o inglês demonstraram que modelos treinados em chinês conseguem classificar notícias falsas em inglês com cerca de 79% de acurácia, enquanto modelos treinados em inglês atingem apenas 55% de acurácia ao tentar classificar dados em chinês.[5] Isso ocorre porque o chinês, neste contexto, apresentou características linguísticas mais complexas e inclusivas; ao treinar em uma linguagem mais rica em nuances discriminatórias, o modelo captura um conjunto de atributos que abrange as formas mais homogêneas do inglês.[5] Para validar essa hipótese, pesquisadores removeram termos chineses com mais de 70% de similaridade com o inglês, o que resultou em uma queda da acurácia para 52%, provando que a eficácia dependia da presença dessas características complexas compartilhadas.[5]

A Discrepância entre o Jornalístico e o Vernáculo das Redes

Outro fator limitante é o hiato estilístico. Notícias legítimas são escritas em linguagem formal, com estruturas complexas, citações e referências.[23] Em contrapartida, a desinformação que circula em redes sociais como WhatsApp, TikTok ou X (Twitter) utiliza linguagem coloquial, gírias, erros gramaticais intencionais, emojis e regionalismos.[9]

Modelos treinados em conjuntos de dados como o LIAR ou notícias do *The New York Times* falham ao processar publicações de usuários comuns porque não reconhecem os padrões de sarcasmo ou ironia típicos da comunicação digital.[9] Por exemplo, no contexto indiano, rumores sobre sequestradores de crianças espalhados pelo WhatsApp em idiomas locais levaram a incidentes de violência real; a falta de recursos de NLP para línguas como Assamese ou Marathi impediu a intervenção tecnológica oportuna.[9] Isso demonstra que a complexidade do treinamento para aplicação real aumenta exponencialmente à medida que o modelo precisa lidar com a "linguagem das ruas" digital em vez da "linguagem do jornal".[9]

Redes Neurais de Grafos (GNN) e a Geometria da Disseminação

Diante das limitações do texto, a pesquisa científica deslocou-se para a análise da estrutura de disseminação. A ideia central é que a verdade e a mentira possuem "formas" geométricas diferentes na maneira como se propagam pelas redes sociais.[12] Enquanto os propagadores de notícias falsas podem controlar o que escrevem, eles têm muito menos controle sobre como a rede reage e repassa a informação.[12]

Assinaturas de Propagação: Velocidade, Profundidade e Amplitude

Estudos empíricos, como os citados na PNAS Nexus, revelam que a falsidade se difunde de forma mais profunda, ampla e rápida do que a verdade em todas as categorias de informação.[26]

Métrica de Rede	Padrão de Notícia Real	Padrão de Fake News
Velocidade	Propagação orgânica e lenta.	Atinge 1.500 pessoas até 6x mais rápido.[26]
Profundidade	Concentrada nos primeiros níveis de compartilhamento.[27]	Penetra em cascata por muitos níveis de retuítes.[27]
Amplitude	Compartilhamentos localizados.	Disseminação transversal entre diversas comunidades.[26]
Estrutura	Comunidades dispersas e	Comunidades estáveis,

	menos organizadas.[13]	densas e interconectadas.[13]
Recorrência	Raramente retorna após o ciclo inicial.	Reaparece múltiplas vezes em ondas sucessivas.[26]

A "circularidade" mencionada na contextualização da monografia pode ser traduzida tecnicamente pelo conceito de "câmaras de eco" e coeficientes de agrupamento (*clustering coefficients*).[25] Notícias falsas tendem a circular em comunidades ideologicamente homogêneas onde a informação é reforçada continuamente, criando uma resistência à correção que é duas a três vezes maior do que em populações mistas.[26]

Fundamentos Matemáticos das GNNs

As Redes Neurais de Grafos (GNNs) operam diretamente sobre a estrutura do grafo $G = (V, E)$, onde V são os nós (usuários ou artigos) e E as arestas (interações).[11] Elas permitem a fusão de dados heterogêneos, integrando o conteúdo textual com o perfil do usuário e a estrutura social.[12]

Redes Neurais Convolucionais de Grafos (GCN)

O modelo GCN, proposto por Kipf e Welling, utiliza uma aproximação de primeira ordem de convoluções espectrais em grafos para aprender representações de nós.[30] A regra de propagação camada a camada é expressa como:

$$H^{(l+1)} = \sigma\left(\tilde{D}^{-\frac{1}{2}}\tilde{A}\tilde{D}^{-\frac{1}{2}}H^{(l)}W^{(l)}\right)$$

Onde $\tilde{A} = A + I_N$ é a matriz de adjacência com auto-conexões, $\tilde{D}$ é a matriz de graus para normalização, e $W^{(l)}$ é a matriz de pesos treináveis.[30] Esta arquitetura é particularmente eficaz para cenários de aprendizado semi-supervisionado, onde apenas uma pequena parcela dos dados possui rótulos de veracidade.[28]

Redes de Atenção em Grafos (GAT)

As GATs introduzem o mecanismo de atenção para atribuir pesos diferentes a vizinhos distintos, refletindo a realidade de que nem todos os usuários em uma rede social possuem a mesma influência.[33] O coeficiente de atenção α_{ij} entre dois nós é calculado como:

$$e_{ij} = \text{LeakyReLU}\left(a^T\right)$$

Esta flexibilidade permite que o modelo foque em "usuários hub" ou padrões específicos de

interações que sinalizam desinformação, sendo resiliente a variações na distribuição de graus da rede.[34]

Aplicações Avançadas e Modelagem de Cascata

A fronteira atual da pesquisa utiliza GNNs para modelar não apenas a rede estática, mas a evolução temporal das cascatas de informação.

1. **Aprendizado Geométrico Profundo (Monti et al., 2019):** Este modelo demonstrou que as notícias falsas podem ser detectadas precocemente, apenas algumas horas após o início da propagação, com uma acurácia (AUC) de 92,7%.[12] Uma vantagem crucial deste método é a sua independência de idioma, pois foca em padrões de conectividade e disseminação que são universais em redes sociais.[12]
2. **GNNs de Evolução Temporal (TGNF):** Ao usar grafos dinâmicos de tempo contínuo (CTDG) em vez de instantâneos estáticos, esses modelos capturam como as arestas surgem e evoluem, permitindo identificar padrões de "coordenação artificial" típicos de botnets.[37]
3. **Redes Topológicas e Sequenciais (TSNN):** Esta abordagem utiliza o conceito de "supernós" para extrair informações representativas da topologia do grafo, combinando-as com informações sequenciais do caminho de difusão por meio de transformadores.[27] Resultados em bases como PolitiFact e GossipCop mostram acurácias superiores a 97%.[27]

Atributos Topológicos Explícitos

A integração de métricas de rede como atributos explícitos em GNNs tem se mostrado valiosa para a interpretabilidade dos modelos. Em domínios onde o conteúdo é propositalmente vago ou ambíguo, como no discurso político, a estrutura da rede carrega sinais discriminatórios fortes.[25]

Métrica Topológica	Implicação para a Detecção
Centralidade de Grau	Identifica usuários centrais na disseminação viral.[25]
Coeficiente de Agrupamento Local	Sinaliza a formação de câmaras de eco densas.[25]
Centralidade de Intermediação	Identifica pontes entre comunidades que podem ser alvos de intervenção.[26]

Modularidade da Cascata	Reflete o quão segmentada é a audiência da notícia.[13]

O Cenário Brasileiro e a Complexidade das Aplicações Reais

No Brasil, a problemática das notícias falsas é intensificada pelo uso massivo de plataformas de mensagens privadas como o WhatsApp, que impõem desafios técnicos únicos devido à criptografia de ponta a ponta e à ausência de APIs públicas para coleta de dados de massa.[38]

Desafios de Dados e Contextualização Nacional

A manipulação da verdade foi uma marca distintiva das eleições presidenciais de 2014 e 2018 no país.[39] Para enfrentar isso, pesquisadores brasileiros desenvolveram o *Fake.Br Corpus*, uma base de dados em português para treinar modelos de detecção que levem em conta as nuances da língua nacional.[40] No entanto, a dedicação de recursos para uma compreensão profunda deste processo ainda é considerada insuficiente frente à escala do problema.[39]

Pesquisas realizadas em instituições como a UFSCar e a USP têm explorado abordagens como o PU-LP (aprendizado de rótulos positivos e não rotulados por propagação), que utiliza mecanismos de atenção para classificar nós em redes heterogêneas de notícias e termos.[40] A constatação recorrente é que modelos treinados em textos de sites de checagem (como "Fato ou Fake") muitas vezes não performam bem em campo porque os textos checados são escritos de forma muito diferente das notícias falsas reais que circulam organicamente.[24]

Multimodalidade e a Próxima Fronteira da Veracidade

O avanço das técnicas de desinformação exige que os sistemas de detecção se tornem multimodais, integrando texto, imagem e vídeo. Muitas vezes, a falsidade não reside no conteúdo isolado, mas na discordância entre as modalidades—por exemplo, uma imagem real usada fora de contexto com um texto enganoso.[41]

Modelos como o MCOT utilizam mecanismos de atenção cross-modal e transporte ótimo para alinhar distribuições de características de texto e imagem.[42] Ao identificar discrepâncias sutis e "pistas de discordância", esses sistemas conseguem detectar manipulações que passariam despercebidas por análises monomodais.[41] Além disso, a robustez contra ataques adversários, como parafraseamento por IA, tornou-se uma prioridade, com modelos como o HEMT-Fake reduzindo as perdas de precisão pela metade em comparação com modelos padrão de NLP.[22]

Conclusões e Recomendações para a Pesquisa de

Monografia

A análise detalhada da literatura científica permite validar a hipótese central de que a detecção baseada puramente em NLP é insuficiente para o ecossistema de desinformação da pós-verdade. A perda de precisão ao transitar entre idiomas e registros sociais não é apenas um problema técnico, mas uma limitação intrínseca da análise de conteúdo que ignora o contexto social e estrutural da disseminação.

A transição para a geometria da rede e o uso de GNNs oferece uma solução para o "problema da tradução", uma vez que os padrões de propagação—a circularidade das câmaras de eco, a velocidade das cascatas e a densidade das comunidades—são assinaturas comportamentais mais universais do que a sintaxe ou o léxico.

Para a validação da monografia, os seguintes pontos são fundamentais:

1. **A Assimetria Linguística:** Modelos treinados em inglês formal não capturam a complexidade de línguas mais ricas ou o vernáculo das redes sociais.[5]
2. **O Valor da Topologia:** A forma da disseminação é um indicador de veracidade tão ou mais poderoso que o conteúdo textual, permitindo detecção precoce e independente de idioma.[12]
3. **A Circularidade como Métrica:** O fenômeno das câmaras de eco e o reforço da crença em comunidades densas fornecem uma base matemática para prever a probabilidade de uma informação ser falsa com base em seu comportamento de rede.[14]

Em suma, a integração de GNNs com análise multimodal e temporal representa o estado da arte na preservação da integridade da informação em sociedades democráticas, oferecendo ferramentas que podem ser adaptadas para o complexo cenário informacional brasileiro.

Referências citadas

1. Full article: Post-truth in practice: evaluating disinformation and its consequences for security decision-making - Taylor & Francis, acessado em março 23, 2026, https://www.tandfonline.com/doi/full/10.1080/23311886.2025.2566300
2. Fake news and critical thinking in the post-truth world – Introduction to Global Change, acessado em março 23, 2026, https://sites.lsa.umich.edu/globalchange/lectures/critical-thinking-in-the-age-of-fake-news/
3. Digital Literacy: Detecting Fake News in a Post-Truth Era, acessado em março 23, 2026, https://digitalcommons.law.uga.edu/cgi/viewcontent.cgi?referer=&httpsredir=1&article=1064&context=cle
4. Post-truth and fake news in scientific communication in Ibero-American journals, acessado em março 23, 2026, https://www.scielo.org.mx/scielo.php?script=sci_arttext&pid=S0188-252X2023000100410&lng=pt&nrm=iso&tlng=en

5. (PDF) Cross-Language Fake News Detection - ResearchGate, acessado em março 23, 2026, https://www.researchgate.net/publication/347563252_Cross-Language_Fake_News_Detection
6. Fake News Detection Landscape: Datasets, Data Modalities, AI Approaches, Their Challenges, and Future Perspectives - IEEE Xplore, acessado em março 23, 2026, https://ieeexplore.ieee.org/iel8/6287639/10820123/10937488.pdf
7. Fake News Detection-Classify Articles as Real or Fake Using NLP - SciTePress, acessado em março 23, 2026, https://www.scitepress.org/publishedPapers/2025/139020/pdf/index.html
8. Challenges and Innovations in LLM-Powered Fake News Detection: A Synthesis of Approaches and Future Directions - arXiv, acessado em março 23, 2026, https://arxiv.org/pdf/2502.00339?
9. The Role of Natural Language Processing (NLP) in Combating Misinformation and Fake News - Cogent Infotech, acessado em março 23, 2026, https://cogentinfo.com/resources/the-role-of-natural-language-processing-nlp-in-combating-misinformation-and-fake-news
10. Cross-lingual Social Misinformation Detector based on Hierarchical Mixture-of-Experts Adapter - ACL Anthology, acessado em março 23, 2026, https://aclanthology.org/2025.coling-main.484.pdf
11. Fake news detection: A survey of graph neural network methods ..., acessado em março 23, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC10036155/
12. Fake News Detection on Social Media using Geometric Deep ..., acessado em março 23, 2026, https://arxiv.org/abs/1902.06673
13. (PDF) Tracking evolving communities in fake news cascades using temporal graphs, acessado em março 23, 2026, https://www.researchgate.net/publication/399618584_Tracking_evolving_communities_in_fake_news_cascades_using_temporal_graphs
14. Full article: The Influence of Media Trust and Normative Role Expectations on the Credibility of Fact Checkers - Taylor & Francis, acessado em março 23, 2026, https://www.tandfonline.com/doi/full/10.1080/17512786.2022.2080102
15. An overview of fake news detection: From a new perspective - PMC, acessado em março 23, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC11955031/
16. A review on fake news detection 3T's: typology, time of detection, taxonomies - PMC, acessado em março 23, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC9664051/
17. Approaches to Identify Fake News: A Systematic Literature Review ..., acessado em março 23, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC7250114/
18. Different Roles for Multiple Perspectives and Rigorous Testing in Scientific Theories and Models: Towards More Open, Context-Appropriate Verificationism - MDPI, acessado em março 23, 2026, https://www.mdpi.com/2409-9287/7/3/54
19. Does Fake News in Different Languages Tell the Same Story? An Analysis of Multi-level Thematic and Emotional Characteristics of News about COVID-19 - PMC, acessado em março 23, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC9510725/

20. Fake News Detection and Classification: A Comparative Study of Convolutional Neural Networks, Large Language Models, and Natural Language Processing Models - MDPI, acessado em março 23, 2026, https://www.mdpi.com/1999-5903/17/1/28
21. Integrating Message Content and Propagation Path for Enhanced False Information Detection Using Bidirectional Graph Convolutional Neural Networks - MDPI, acessado em março 23, 2026, https://www.mdpi.com/2076-3417/15/7/3457
22. Explainable multilingual and multimodal fake-news detection: toward robust and trustworthy AI for combating misinformation - PMC, acessado em março 23, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC12727966/
23. Detecting Misinformation in News Articles via Natural Language Processing - Stanford University, acessado em março 23, 2026, https://web.stanford.edu/class/archive/cs/cs224n/cs224n.1244/final-projects/SiyaGoelThuLeTiaVasudeva.pdf
24. Pesquisadores criam modelo de IA para detectar fake news - SACI - UFSCar, acessado em março 23, 2026, https://www.saci.ufscar.br/servico_release?id=153931&pro=3
25. Enhancing Fake-News Detection with Node-Level Topological Features - arXiv, acessado em março 23, 2026, https://arxiv.org/html/2512.09974v1
26. Containing misinformation: Modeling spatial games of fake news ..., acessado em março 23, 2026, https://academic.oup.com/pnasnexus/article/3/3/pgae090/7614685
27. Topological and Sequential Neural Network Model for Detecting Fake News - ResearchGate, acessado em março 23, 2026, https://www.researchgate.net/publication/376622725_Topological_and_Sequential_Neural_Network_Model_for_Detecting_Fake_News
28. Paper summary: Graph Convolutional Networks | by Sanna Persson - Medium, acessado em março 23, 2026, https://sannaperzon.medium.com/paper-summary-graph-convolutional-networks-c8f8329da687
29. A network-based positive and unlabeled learning approach for fake news detection - PMC, acessado em março 23, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC8601374/
30. SEMI-SUPERVISED CLASSIFICATION WITH GRAPH CONVOLUTIONAL NETWORKS - OpenReview, acessado em março 23, 2026, https://openreview.net/pdf?id=SJU4ayYgl
31. [1609.02907] Semi-Supervised Classification with Graph Convolutional Networks - arXiv, acessado em março 23, 2026, https://arxiv.org/abs/1609.02907
32. semi-supervised classification with graph convolutional networks - arXiv, acessado em março 23, 2026, https://arxiv.org/pdf/1609.02907
33. Graph Attention Networks - OpenReview, acessado em março 23, 2026, https://openreview.net/forum?id=rJXMpikCZ
34. Graph Attention Network Overview - Emergent Mind, acessado em março 23, 2026, https://www.emergentmind.com/topics/graph-attention-network
35. Graph Attention Networks - Petar Veličković, acessado em março 23, 2026,

https://petar-v.com/GAT/
36. A Brief Introduction to Graph Attention Networks | GAT – Weights & Biases - Wandb, acessado em março 23, 2026, https://wandb.ai/graph-neural-networks/GAT/reports/A-Brief-Introduction-to-Graph-Attention-Networks---Vmlldzo1MzAxMjEw
37. Temporally evolving graph neural network for fake news detection - Computer Science, acessado em março 23, 2026, https://www.cs.emory.edu/~kshu5/files/IPM_TGNN.pdf
38. FakeWhatsApp.BR: Detecção de Desinformação e Desinformadores em Grupos Públicos do WhatsApp em PT-BR - Repositório Institucional UFC - Universidade Federal do Ceará, acessado em março 23, 2026, https://repositorio.ufc.br/bitstream/riufc/63379/3/2021_dis_lcccunha.pdf
39. DETECÇÃO DE FAKE NEWS EM REDES SOCIAIS COM O USO DE REDES NEURAIS RECORRENTES, REDES NEURAIS GRÁFICAS E TRANSFORMERS, acessado em março 23, 2026, https://tede2.pucsp.br/bitstream/handle/39999/1/Carlos%20Eduardo%20de%20Souza.pdf
40. UNIVERSID ADE DE SÃ O PA ULO - Biblioteca Digital de Teses e Dissertações da USP, acessado em março 23, 2026, https://www.teses.usp.br/teses/disponiveis/55/55134/tde-22122023-125502/publico/MarianaCaravantideSouza_DO_revisada.pdf
41. Multi-modal Misinformation Detection: Approaches, Challenges and Opportunities - arXiv, acessado em março 23, 2026, https://arxiv.org/html/2203.13883v7
42. Multimodal Fake News Detection with Contrastive Learning and Optimal Transport, acessado em março 23, 2026, https://www.frontiersin.org/journals/computer-science/articles/10.3389/fcomp.2024.1473457/full